

Learning Part-2


Algoritma Naïve Bayes

(Kasus : Klasifikasi)

Kuliah : 17 April 2024

Klasifikasi

- Merupakan proses pembelajaran suatu fungsi tujuan yang **memetakan** tiap himpunan **atribut x** ke satu dari **label kelas y** yang didefinisikan sebelumnya.



Model Klasifikasi

- Pemodelan **Deskriptif**

Model Klasifikasi yang dpt berfungsi sbg alat **penjelasan** untuk membedakan **obyek-obyek** dalam **kelas-kelas** yang berbeda.

- Pemodelan **Prediktif**

Model klasifikasi yang dapat digunakan untuk **memprediksi label kelas** yang tidak diketahui pada suatu *object/record*.

Klasifikasi memerlukan Training Set

- Klasifikasi adalah proses pembelajaran secara terbimbing (*supervised learning*)
- Untuk melakukan klasifikasi, dibutuhkan *training set* sebagai data pembelajaran
- Setiap *sampel* dari training set memiliki *atribut* dan *class label*

Dua Tahapan Klasifikasi

- *Learning (training):*

Pembelajaran menggunakan **data training** (untuk *Naïve Bayesian Classifier*, nilai **probabilitas** dihitung dalam proses pembelajaran)

- **Testing:**

Menguji model menggunakan data testing

Sumber: Bing Liu, Web Data Mining



Akurasi

$$\text{Akurasi} = \frac{\text{Jml Prediksi Yang Benar}}{\text{Jml Prediksi keseluruhan}}$$

$$\text{Error} = \frac{\text{Jml Prediksi Yang Salah}}{\text{Jml Prediksi keseluruhan}}$$

Teori Bayesian: Sebagai Dasar

$$P(H|X) = \frac{P(X|H)P(H)}{P(X)}$$

- $P(H|X)$, yaitu peluang hipotesa H berdasar kondisi X
- X : data sampel dengan kelas (label) yang tidak diketahui
- H : merupakan hipotesa bahwa X adalah data dengan kelas (label) C .
- $P(H)$: peluang dari hipotesa H
- $P(X)$ adalah peluang dari X yang diamati
- $P(X|H)$: peluang X , berdasarkan kondisi pada hipotesa H

Naïve Bayesian Classifier

- Adalah metode classifier yang berdasarkan **probabilitas** dan Teorema **Bayesian** dengan asumsi bahwa setiap variabel **X** bersifat bebas(*independence*)
- Dengan kata lain, **Naïve Bayesian Classifier** mengasumsikan bahwa keberadaan sebuah atribut (variabel) tidak ada kaitannya dengan beradaan atribut (variabel) yang lain

Naïve Bayesian Classifier

- Karena asumsi **atribut tidak saling terkait** (*conditionally independent*), maka:

$$P(X | C_i) = \prod_{k=1}^n P(x_k | C_i)$$

- Bila $P(X | C_i)$ dapat diketahui melalui perhitungan di atas, maka klas (label) dari data sampel X adalah klas (label) yang memiliki $P(X | C_i) * P(C_i)$ maksimum

Naïve Bayesian Classifier

- Namun jika atribut ke-i **bersifat kontinu**, maka $P(x_i | C)$ diestimasi dengan fungsi densitas Gauss.
- Distribusi normal adalah distribusi dari variabel acak kontinu. Kadang-kadang distribusi normal disebut juga dengan distribusi Gauss. Distribusi ini merupakan distribusi yang paling penting dan paling banyak digunakan di bidang statistika.

$$f(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{\frac{-(x-\mu)^2}{2\sigma^2}} \quad e = 2,7183$$

dengan μ = mean, dan σ = deviasi standar.

Naïve Bayes

- Dataset

Umur	Pendapatan	Mhs	Rating Kredit	Beli Komputer
<=30	tinggi	bukan	fair	Tdk
<=30	tinggi	bukan	excellent	tdk
30...40	tinggi	bukan	fair	ya
>40	sedang	bukan	fair	ya
>40	rendah	ya	fair	ya
>40	rendah	ya	excellent	tdk
31...40	rendah	ya	excellent	ya
<=30	sedang	bukan	fair	tdk
<=30	rendah	ya	fair	ya
>40	sedang	ya	fair	ya
<=30	sedang	ya	excellent	ya
31...40	sedang	bukan	excellent	ya
31...40	tinggi	ya	fair	ya
>40	sedang	bukan	excellent	tdk

class:

C1: Beli Komputer: **ya**

C2: Beli Komputer: **tdk**

bila data baru yg blm memiliki class sbb:

X =(umur<=30, pendapatan=sedang, mhs=ya, rating kredit= Fair)

Hitung $P(X_k|C_i)$ utk setiap class i

- $X = (\text{umur} \leq 30, \text{pendapatan} = \text{sedang}, \text{mhs} = \text{ya}, \text{rating kredit} = \text{Fair})$

Umur	Pendapatan	Mhs	Rating Kredit	Beli Komputer
≤ 30	tinggi	bukan	fair	tdk
≤ 30	tinggi	bukan	excellent	tdk
≤ 30	sedang	bukan	fair	tdk
≤ 30	rendah	ya	fair	ya
≤ 30	sedang	ya	excellent	ya
> 40	rendah	ya	excellent	tdk
> 40	sedang	bukan	fair	ya
> 40	rendah	ya	fair	ya
> 40	sedang	ya	fair	ya
> 40	sedang	bukan	excellent	tdk
30...40	tinggi	bukan	fair	ya
31...40	rendah	ya	excellent	ya
31...40	sedang	bukan	excellent	ya
31...40	tinggi	ya	fair	ya

$$P(\text{umur} \leq 30 \mid \text{beli_komputer} = \text{ya}) = > \quad 2/9 = 0.220$$

$$P(\text{umur} \leq 30 \mid \text{beli_komputer} = \text{tdk}) = > \quad 3/5 = 0.600$$

Hitung $P(X_k | C_i)$ utk setiap class i

- $X = (\text{umur} \leq 30, \text{pendapatan} = \text{sedang}, \text{mhs} = \text{ya}, \text{rating kredit} = \text{Fair})$

ID	Umur	Pendapatan	Mhs	Rating Kredit	Beli Komputer
1	>40	rendah	ya	excellent	tdk
2	≤ 30	rendah	ya	fair	ya
3	>40	rendah	ya	fair	ya
4	31...40	rendah	ya	excellent	ya
5	≤ 30	sedang	bukan	fair	tdk
6	>40	sedang	bukan	excellent	tdk
7	≤ 30	sedang	ya	excellent	ya
8	>40	sedang	bukan	fair	ya
9	>40	sedang	ya	fair	ya
10	31...40	sedang	bukan	excellent	ya
11	≤ 30	tinggi	bukan	fair	tdk
12	≤ 30	tinggi	bukan	excellent	tdk
13	30...40	tinggi	bukan	fair	ya
14	31...40	tinggi	ya	fair	ya

$P(\text{pendapatan} = \text{sedang} \mid \text{beli_komputer} = \text{ya}) \Rightarrow 4/9 = 0.444$

$P(\text{pendapatan} = \text{sedang} \mid \text{beli_komputer} = \text{tdk}) \Rightarrow 2/5 = 0.400$

Hitung $P(X_k | C_i)$ utk setiap class i

$X = (\text{umur} \leq 30, \text{pendapatan} = \text{sedang}, \text{mhs} = \text{ya}, \text{rating kredit} = \text{Fair})$

ID	Umur	Pendapatan	Mhs	Rating Kredit	Beli Komputer
1	≤ 30	sedang	bukan	fair	tdk
2	> 40	sedang	bukan	excellent	tdk
3	≤ 30	tinggi	bukan	fair	tdk
4	≤ 30	tinggi	bukan	excellent	tdk
5	> 40	sedang	bukan	fair	ya
6	31...40	sedang	bukan	excellent	ya
7	30...40	tinggi	bukan	fair	ya
8	> 40	rendah	ya	excellent	tdk
9	≤ 30	rendah	ya	fair	ya
10	> 40	rendah	ya	fair	ya
11	31...40	rendah	ya	excellent	ya
12	≤ 30	sedang	ya	excellent	ya
13	> 40	sedang	ya	fair	ya
14	31...40	tinggi	ya	fair	ya

$P(\text{mhs} = \text{ya} | \text{beli_komputer} = \text{ya}) \Rightarrow 6/9 = 0.670$

$P(\text{mhs} = \text{ya} | \text{beli_komputer} = \text{tdk}) \Rightarrow 1/5 = 0.200$

Hitung $P(X_k|C_i)$ utk setiap class i

$X = (\text{umur} \leq 30, \text{pendapatan} = \text{sedang}, \text{mhs} = \text{ya}, \text{rating kredit} = \text{Fair})$

ID	Umur	Pendapatan	Mhs	Rating Kredit	Beli Komputer
1	≤ 30	tinggi	bukan	excellent	tdk
2	> 40	sedang	bukan	excellent	tdk
3	> 40	rendah	ya	excellent	tdk
4	31...40	sedang	bukan	excellent	ya
5	31...40	rendah	ya	excellent	ya
6	≤ 30	sedang	ya	excellent	ya
7	≤ 30	sedang	bukan	fair	tdk
8	≤ 30	tinggi	bukan	fair	tdk
9	> 40	sedang	bukan	fair	ya
10	30...40	tinggi	bukan	fair	ya
11	≤ 30	rendah	ya	fair	ya
12	> 40	rendah	ya	fair	ya
13	> 40	sedang	ya	fair	ya
14	31...40	tinggi	ya	fair	ya

$P(\text{rating kredit} = \text{fair} | \text{beli_komputer} = \text{ya}) \Rightarrow 6/9 = 0.670$

$P(\text{rating kredit} = \text{fair} | \text{beli_komputer} = \text{tdk}) \Rightarrow 2/5 = 0.400$

$$P(X | C_i) = \prod_{k=1}^n P(x_k | C_i)$$

Hitung P(X _k C _i) utk setiap class I		
P(umur≤30 beli_computer=ya)	= 2/9	0.222
P(umur≤30 beli_computer=tdk)	= 3/5	0.600
P(pendapatan=sedang beli_computer=ya)	= 4/9	0.444
P(pendapatan=sedang beli_computer=tdk)	= 2/5	0.400
P(mhs=ya beli_computer=ya)	= 6/9	0.667
P(mhs=ya beli_computer=tdk)	= 1/5	0.200
P(rating kredit=fair beli_computer=ya)	= 6/9	0.667
P(rating kredit=ya beli_computer=tdk)	= 2/5	0.400

- Hitung P(X | C_i) untuk setiap Class:
 - P(X | beli_computer="ya") = 0.222 x 0.444 x 0.667 x 0.667 = 0.044
 - P(X | beli_computer="tdk") = 0.600 x 0.400 x 0.200 x 0.400 = 0.019

$$P(X | C_i) * P(C_i):$$

- $P(X | \text{beli_computer}=\text{"ya"}) * P(\text{beli_computer}=\text{"ya"})$
 $0.044 * (9/14) = 0.028$
- $P(X | \text{beli_computer}=\text{"tdk"}) * P(\text{beli_computer}=\text{"tdk"})$
 $0.019 * (5/14) = 0.007$

X memiliki class "beli_computer=**ya**"

karena

$P(X | \text{beli_computer}=\text{"ya"})$ memiliki nilai **maksimum** pada perhitungan di atas

Contoh Kasus (2)

- Misalnya terdapat ingin diketahui apakah suatu objek masuk dalam kategori dipilih untuk perumahan atau tidak dengan algoritma Naive Bayes Classifier. Untuk menetapkan suatu daerah akan dipilih sebagai lokasi untuk mendirikan perumahan, telah dihimpun 10 aturan.

- Ada 4 atribut yang digunakan, yaitu:
 - harga tanah per meter persegi (C1),
 - jarak daerah tersebut dari pusat kota (C2),
 - ada atau tidaknya angkutan umum di daerah tersebut (C3), dan
 - keputusan untuk memilih daerah tersebut sebagai lokasi perumahan (C4).

Aturan ke-	Harga tanah (C1)	Jarak dari pusat kota (C2)	Ada angkutan umum (C3)	Dipilih untuk perumahan (C4)
1	Murah	Dekat	Tidak	Ya
2	Sedang	Dekat	Tidak	Ya
3	Mahal	Dekat	Tidak	Ya
4	Mahal	Jauh	Tidak	Tidak
5	Mahal	Sedang	Tidak	Tidak
6	Sedang	Jauh	Ada	Tidak
7	Murah	Jauh	Ada	Tidak
8	Murah	Sedang	Tidak	Ya
9	Mahal	Jauh	Ada	Tidak
10	Sedang	Sedang	Ada	Ya

- Probabilitas kemunculan setiap nilai untuk atribut Harga Tanah (C1)

Harga tanah	Jumlah kejadian "Dipilih"		Probabilitas	
	Ya	Tidak	Ya	Tidak
Murah	2	1	2/5	1/5
Sedang	2	1	2/5	1/5
Mahal	1	3	1/5	3/5
<i>Jumlah</i>	5	5	1	1

- Probabilitas kemunculan setiap nilai untuk atribut Jarak dari Pusat Kota (C2)

Jarak Dari Pusat Kota	Jumlah kejadian "Dipilih"		Probabilitas	
	Ya	Tidak	Ya	Tidak
Dekat	3	0	3/5	0
Sedang	2	1	2/5	1/5
Jauh	0	4	0	4/5
<i>Jumlah</i>	5	5	1	1

- Probabilitas kemunculan setiap nilai untuk atribut Ada Angkutan Umum (C3)

Angkutan Umum	Jumlah kejadian "Dipilih"		Probabilitas	
	Ya	Tidak	Ya	Tidak
Ada	1	3	1/5	3/5
Tidak	4	2	4/5	2/5
<i>Jumlah</i>	5	5	1	1

- Probabilitas kemunculan setiap nilai untuk atribut Dipilih untuk perumahan (C4)

Dipilih Untuk Perumahan	Jumlah kejadian “Dipilih”		Probabilitas	
	Ya	Tidak	Ya	Tidak
<i>Jumlah</i>	5	5	1/2	1/2

- Test Set: Berdasarkan data tersebut, apabila diketahui suatu daerah dengan harga tanah **MAHAL**, jarak dari pusat kota **SEDANG**, dan **ADA** angkutan umum, maka dapat dihitung:

$$YA = P(Ya | Tanah=MAHAL) * P(Ya | Jarak=SEDANG) * \\ P(Ya | Angkutan=ADA) * P(Ya)$$

$$= 1/5 \times 2/5 \times 1/5 \times 5/10 = 2/125 = 0,008$$

$$TIDAK = P(Tidak | Tanah=MAHAL) * P(Tidak | Jarak=SEDANG) * \\ P(Tidak | Angkutan=ADA) * P(Tidak)$$

$$= 3/5 \times 1/5 \times 3/5 \times 5/10 = 2/125 = 0,036$$

- Nilai probabilitas dapat dihitung dengan melakukan normalisasi terhadap likelihood tersebut sehingga jumlah nilai yang diperoleh = 1

$$\begin{array}{lcl} \text{Probabilitas Ya} = & \frac{0,008}{0,008 + 0,036} = 0,182. & \\ \text{Probabilitas Tidak} = & \frac{0,036}{0,008 + 0,036} = 0,818. & \end{array} \quad \left. \vphantom{\begin{array}{l} \\ \end{array}} \right\} \text{Klasifikasi : TIDAK}$$

- Untuk jenis data harga tanah dan jarak pusat kota yang kontinue, misalnya :

<u>Aturan ke-</u>	Harga tanah (C1)	Jarak dari pusat kota (C2)	Ada angkutan umum (C3)	Dipilih untuk perumahan (C4)
1	100	2	Tidak	Ya
2	200	1	Tidak	Ya
3	500	3	Tidak	Ya
4	600	20	Tidak	Tidak
5	550	8	Tidak	Tidak
6	250	25	Ada	Tidak
7	75	15	Ada	Tidak
8	80	10	Tidak	Ya
9	700	18	Ada	Tidak
10	180	8	Ada	<u>Ya</u>

- Probabilitas kemunculan setiap nilai untuk atribut Harga Tanah (C1)

	Ya	Tidak
1	100	600
2	200	550
3	500	250
4	80	75
5	180	700
Mean (μ)	212	435
Deviasi standar (σ)	168,8787	261,9637

- Probabilitas kemunculan setiap nilai untuk atribut Jarak dari Pusat Kota (C2)

	Ya	Tidak
1	2	20
2	1	8
3	3	25
4	10	15
5	8	18
Mean (μ)	4,8	17,2
Deviasi standar (σ)	3,9623	6,3008

- Probabilitas kemunculan setiap nilai untuk atribut Angkutan Umum (C3)

Angkutan Umum	Jumlah kejadian "Dipilih"		Probabilitas	
	Ya	Tidak	Ya	Tidak
Ada	1	3	1/5	3/5
Tidak	4	2	4/5	2/5
<i>Jumlah</i>	5	5	1	1

- Probabilitas kemunculan setiap nilai untuk atribut Dipilih untuk Perumahan (C4)

Dipilih Untuk Perumahan	Jumlah kejadian “Dipilih”		Probabilitas	
	Ya	Tidak	Ya	Tidak
<i>Jumlah</i>	5	5	1/2	1/2

- Apabila diberikan $C1 = 300$, $C2 = 17$, $C3 =$ Tidak, maka:

$$f(C1 = 300 | ya) = \frac{1}{\sqrt{2\pi} (168,8787)} e^{\frac{-(300-212)^2}{2(168,8787)^2}} = 0,0021.$$

$$f(C1 = 300 | tidak) = \frac{1}{\sqrt{2\pi} (261.9637)} e^{\frac{-(300-435)^2}{2(261.9637)^2}} = 0,0013.$$

$$f(C2 = 17 | ya) = \frac{1}{\sqrt{2\pi} (3.9623)} e^{\frac{-(17-4,8)^2}{2(3.9623)^2}} = 0,0009.$$

$$f(C2 = 17 | tidak) = \frac{1}{\sqrt{2\pi} (6,3008)} e^{\frac{-(17-17,2)^2}{2(6,3008)^2}} = 0,0633.$$

$$\begin{aligned}\text{Likelihood Ya} &= (0,0021) \times (0,0009) \times 4/5 \times 5/10 \\ &= 0,000000756.\end{aligned}$$

$$\begin{aligned}\text{Likelihood Tidak} &= (0,0013) \times (0,0633) \times 2/5 \times \\ &5/10 \\ &= 0,000016458.\end{aligned}$$

- Nilai probabilitas dapat dihitung dengan melakukan normalisasi terhadap likelihood tersebut sehingga jumlah nilai yang diperoleh = 1

$$\begin{array}{lcl} \text{Probabilitas Ya} = & \frac{0,000000756}{0,000000756 + 0,000016458} = 0,0439. & \\ \text{Probabilitas Tidak} = & \frac{0,000016458}{0,000000756 + 0,000016458} = 0,9561. & \end{array} \left. \vphantom{\begin{array}{l} \\ \end{array}} \right\} \text{Klasifikasi : TIDAK}$$

Naïve Bayesian: Summary

- Kekuatan:
 - Mudah diimplementasi
 - Memberikan hasil yang baik untuk banyak kasus
- Kelemahan:
 - Harus mengasumsi bahwa antar fitur tidak terkait (*independent*) *Dalam realita*, keterkaitan itu ada
 - Keterkaitan tersebut tidak dapat dimodelkan oleh Naïve Bayesian Classifier

Latihan

ID	OUTLOOK	TEMPERATUR	HUMIDITY	WINDY	PLAY
1	Sunny	Hot	High	FALSE	NO
2	Sunny	Hot	High	TRUE	NO
3	Cloudy	Hot	High	FALSE	YES
4	Rainy	Mild	High	FALSE	YES
5	Rainy	Cool	Normal	FALSE	YES
6	Rainy	Cool	Normal	TRUE	YES
7	Cloudy	Cool	Normal	TRUE	YES
8	Sunny	Mild	High	FALSE	NO
9	Sunny	Cool	Normal	FALSE	YES
10	Rainy	Mild	Normal	FALSE	YES
11	Sunny	Mild	Normal	TRUE	YES
12	Cloudy	Mild	High	TRUE	YES
13	Cloudy	Hot	Normal	FALSE	YES
14	Rainy	Mild	High	TRUE	NO

Tentukan *class label* dari X:

X =(Outlook=Rainy, Temperature=Cool, Humidity=High,
Windy=False)