


Deep Learning

Tujuan Pembelajaran

- Mahasiswa mampu memahami konsep machine learning (ML) dan deep learning (DL)

Overview




Machine Learning (Pemelajaran Mesin)

- The science and engineering of making intelligent machines [John McCarthy]
- Sebuah cabang dari ilmu komputer yang berkaitan dengan bagaimana mensimulasikan kecerdasan pada komputer
- Kemampuan mesin untuk meniru kecerdasan manusia
- Salah satu cabang dari kecerdasan buatan yang membahas mengenai pembangunan sistem yang didapat berdasarkan pada pemelajaran data, atau sebuah studi yang mempelajari cara untuk memprogram sebuah komputer untuk belajar [Wikipedia]

Algoritma Machine Learning

- Supervised Learning
 - DT (C4.5), NBC, KNN, ANN, SVM, LR, CART, dll
- Unsupervised Learning
 - Apriori, FPGrowth, K-Means, K-Medoids, DBSCAN, C-Means, SOM, dll
- Reinforcement Learning
 - Genetic Algorithm, Dynamic Programming, Generalized Policy Iteration, Monte Carlo, dll
- Deep Learning
 - Convolutional Neural Networks (CNN), Deep Belief Networks (DBN), Restricted Boltzmann Machine (RBM), Stacked Autoencoders, dll


Learning Evolution



Deep Learning (Pemelajaran Dalam)

- Deep learning adalah bagian dari algoritma machine learning yang menggunakan layer bertingkat (multiple layer) untuk mengekstraksi fitur-fitur skala tinggi dari data masukan [Deng & Yu, 2014].
- Sederhananya, deep learning adalah segala hal yang menggunakan jaringan syaraf / ANN dengan lebih banyak neuron, layer dan interkoneksi.
- DL masih jauh dari kemampuan otak manusia, namun DL sudah lebih mengarah ke sana.

Deep Learning Performance



Sumber: <https://www.ibm.com/blogs/systems/deep-learning-performance-breakthrough/>

Single Layer Perceptron, MLP, Deep Learning







Figure 12.2 Deep network architecture with multiple layers.

Model Deep Learning


#	Model / Arsitektur	Contoh Penerapan / Aplikasi
1	Recurrent Neural Network (RNN)	Speech recognition, handwriting recognition
2	LSTM / GRU Network	Natural language processing, text compression, handwriting recognition, speech recognition, gesture recognition, image captioning
3	Convolutional Neural Networks (CNN)	Image recognition, video analysis, natural language processing
4	Deep Belief Networks (DBN)	Image recognition, information retrieval, Natural language understanding, failure prediction
5	Deep Stacking Networks (DSN)	Information retrieval, continuous speech recognition

Sumber: <https://developer.ibm.com/articles/cc-machine-learning-deep-learning-architectures/>

Machine Learning (Konvensional)



Deep Learning



Pengantar Deep Learning

Pendekatan klasifikasi secara konvensional umumnya melakukan ekstraksi fitur secara terpisah kemudian dilanjutkan proses pembelajaran menggunakan metode klasifikasi konvensional


Kelemahan pendekatan konvensional:

- Memerlukan waktu dan pengetahuan lebih untuk ekstraksi fitur
- Sangat tergantung pada satu domain permasalahan saja sehingga tidak berlaku general

Pendekatan klasifikasi berbasis Deep learning mempelajari representasi hirarki (pola fitur) secara otomatis melalui beberapa tahapan proses *feature learning*

Convolutional Neural Network (CNN)

- CNN merupakan metode Deep Learning yang merupakan salah satu jenis arsitektur ANN
- Ada tiga layer utama yaitu *convolutional layer*, *pooling layer*, dan *fully connected layer*



Bagian Arsitektur CNN

1. Convolutional Layer

Menggunakan operasi konvolusi dari teori pengolahan citra.

Berperan untuk menghasilkan “*feature image/map*,” gambar yang berisi fitur penting dari gambar input.

2. Pooling Layer

Berperan untuk memperkecil dimensi *feature image*.

Jenis: Max-pooling, Average pooling, dll.


3. Fully-connected Layer

Multi Layer Perceptron biasa

Berperan untuk menghasilkan output klasifikasi akhir

Convolutional Layer

- *Convolutional layer* merupakan proses konvolusi citra input dengan filter yang menghasilkan *feature map*
- Ukuran matrik citra dan ukuran matrik filter akan mempengaruhi ukuran matrik *feature map*



Convolutional Layer

Dalam dunia Ilmu Komputer, konvolusi erat kaitannya dengan bidang ilmu *Image Processing*.


Konvolusi merupakan sebuah operasi antar dua buah matrix...

Matrix Gambar (input)

Matrix Kernel

... sedemikian sehingga menghasilkan sebuah **matrix yang berisi fitur-fitur penting dari input**.


Convolutional Layer



Convolutional Layer

- Proses konvolusi citra dengan filter dilakukan sliding filter mulai dari kiri atas dari matrik citra sampai kanan bawah
- Rumus konvolusi dari citra I dengan filter K sebagai berikut:

$$(I * K)(i, j) == \sum_m \sum_n I(m, n) K(i + m, j + n)$$



Convolutional Layer

1. Jadi, layer konvolusi itu gunanya buat apa?


Mencari fitur-fitur penting sebuah gambar.

fitur memberikan nilai informasi yang jauh lebih besar dibanding gambar input itu sendiri.

2. Kernel konvolusi kan ada banyak jenisnya, pakai yang mana?

- Bukan kita yang menentukan apa kernelnya, tapi CNN yang akan belajar dan mencari kernel apa yang tepat!
- Dengan kata lain, nilai-nilai dalam kernel itulah yang dipelajari oleh CNN.
- Nilai dalam kernel = Weight yang harus dipelajari.


Convolutional Layer



Feature-map ada banyak


Convolutional Layer

Banyak Kernel = Banyak Jenis Fitur



Convolutional Layer

Tujuan Layer Konvolusi ditumpuk



Informasi semakin lebih bermakna

Pooling Layer

Merupakan layer yang berperan untuk mereduksi dimensionalitas output dari layer sebelumnya.


Membuat ukuran *feature image* menjadi lebih kecil.

Mengapa kita membutuhkan ini?

1. Curse of dimensionality
 - Ingat problem awal kita sebelum masuk ke CNN.
 - Makin besar dimensi = Network makin sulit dilatih.
2. Informasi gambar tidak bergantung pada posisi ruang.
 - Gambar kucing ya gambar kucing, sekalipun kepalanya lagi miring, atau posisi hidungnya ada diatas gambar.
 - *Feature image* di-pool = Informasi “kucing” menjadi padat dan singular.
 - *Translational Invariance*.

Pooling Layer

- *Pooling layer* digunakan untuk mengurangi ukuran gambar menjadi lebih kecil (*down sample*) dan mengekstrak *salient features*
- *Pooling layer* yang umum digunakan adalah *Maximum pooling* dan *Average pooling*



Pooling Layer

Merupakan layer yang berperan untuk mereduksi dimensionalitas output dari layer sebelumnya.


Membuat ukuran *feature image* menjadi lebih kecil.

Mengapa kita membutuhkan ini?

1. Curse of dimensionality
 - Ingat problem awal kita sebelum masuk ke CNN.
 - Makin besar dimensi = Network makin sulit dilatih.
2. Informasi gambar tidak bergantung pada posisi ruang.
 - Gambar kucing ya gambar kucing, sekalipun kepalanya lagi miring, atau posisi hidungnya ada diatas gambar.
 - *Feature image* di-pool = Informasi “kucing” menjadi padat dan singular.
 - *Translational Invariance*.

Fully Connected Layer

- *Fully connected layer* merupakan arsitektur *Multi-layer* ANN
- *Feature map* hasil dari proses konvolusi dan pooling, selanjutnya dilakukan proses *flatten* yaitu merubah matrix menjadi vektor sebagai inputan *fully connected layer*



Fully Connected Layer

Hanyalah sebuah Multi-Layer Perceptron.


- Bernama “*fully-connected*” karena setiap neuron di layer satu terhubung ke seluruh neuron di layer lain.
- Berbeda dengan apa yang dilakukan di Convolution dan Pooling Layer.
- Berperan untuk melakukan klasifikasi akhir.

Disetiap layer *fully-connected* activation function yang digunakan bebas, Kecuali, akhir layer *fully-connected*.


Layer akhir bertugas memberikan probabilitas klasifikasi.

Softmax Function.


Proses Fully-Connected Layer




Proses Fully-Connected Layer



Proses Fully-Connected Layer




Arsitektur CNN Full Version



Contoh Implementasi arsitektur CNN pada pengenalan angka

- Citra input 28x28
- Layer pertama konvolusi dengan 16 filter yang berukuran 3x3
- Layer kedua Max pooling dengan filter yang berukuran 2x2
- Layer ketiga konvolusi dengan 32 filter yang berukuran 3x3
- Layer keempat Max pooling dengan filter yang berukuran 2x2
- Layer Flatten dilanjutkan 1 hidden layer dengan 64 neuron
- Output layer mempunyai 10 neuron (10 label kelas)
- Fungsi aktivasi pada output layer menggunakan Softmax



Contoh implementasi arsitektur CNN pada pengenalan angka

1. Define Model CNN

```
from keras.models import Sequential
from keras.layers import Conv2D, MaxPooling2D, Flatten, Dense

model2 = Sequential()
model2.add(Conv2D(16, (3,3), activation='relu', input_shape=(28,28,1), padding='same'))
model2.add(MaxPooling2D(2,2))
model2.add(Conv2D(32, (3,3), activation='relu', padding='same'))
model2.add(MaxPooling2D(2,2))
model2.add(Flatten())
model2.add(Dense(64, activation='relu'))
model2.add(Dense(10, activation='softmax'))
model2.summary()
```

Model: "sequential_1"

Layer (type)	Output Shape	Param #
conv2d (Conv2D)	(None, 28, 28, 16)	160
max_pooling2d (MaxPooling2D)	(None, 14, 14, 16)	0
conv2d_1 (Conv2D)	(None, 14, 14, 32)	4640
max_pooling2d_1 (MaxPooling2D)	(None, 7, 7, 32)	0
flatten_1 (Flatten)	(None, 1568)	0
dense_2 (Dense)	(None, 64)	100416
dense_3 (Dense)	(None, 10)	650

Total params: 105,866

Trainable params: 105,866

Non-trainable params: 0


Contoh implementasi arsitektur CNN pada pengenalan angka

2. Compile Model, Fit Model, Save Model, dan Evaluasi Model CNN

```
model.compile(optimizer='adam',loss='categorical_crossentropy',metrics=['acc'])  
history =  
model.fit(X_train,y_train,epochs=10,batch_size=100,validation_data=(X_test,y_test))  
model.save('my_model2.h5')  
model.evaluate(X_test,y_test)
```

313/313 [=====] - 1s 3ms/step - loss: 0.0304 - acc: 0.9897

[0.03035075031220913, 0.9897000193595886]



Contoh implementasi arsitektur CNN pada pengenalan angka

3. Load Model CNN dan Prediction

```
import numpy as np
from keras.models import load_model

model_simpan2 = load_model('my_model2.h5')
pred = model_simpan2.predict(X_test)
print('label actual:', np.argmax(y_test[30]))
print('label prediction:', np.argmax(pred[30]))
```

```
label actual: 3
label prediction: 3
```

Contoh Implementasi pada Pengenalan Angka


```
import matplotlib.pyplot as plt

epochs = range(10)
loss1 = history1.history['loss']
val_loss1 = history1.history['val_loss']
plt.plot(epochs, loss1, 'r', label='train loss ANN')
plt.plot(epochs, val_loss1, 'b', label='val loss ANN')

loss2 = history2.history['loss']
val_loss2 = history2.history['val_loss']
plt.plot(epochs, loss2, 'r+', label='train loss CNN')
plt.plot(epochs, val_loss2, 'b+', label='val loss CNN')


plt.legend()
```

Perbandingan Loss dari Model CNN dan model ANN




Varian dari Arsitektur CNN dan Tipe Aplikasinya

Aplikasi	Arsitektur CNN
Image Classification	• LeNet-5 (1998) • AlexNet (2012) • GoogLeNet/Inception (2014) • VGGNet (2014) • ResNet (2015)
Object Detection	• R-CNN (2013) • Fast R-CNN (2014) • Faster R-CNN (2015) • Single Shot Detector (SSD) (2016) • YOLO (2016), YOLOv3 (2018), YOLOv4 (2020), YOLOv5 (2020)
Semantic (Instance) Segmentation	• Fully Convolutional Network (FCN) (2015) • U-Net (2015) • Feature Pyramid Network (FPN) (2016) • Mask R-CNN (2017) • DeepLab (2016), DeepLabv3 (2017), DeepLabv3+ (2018)
Generative model	• Autoencoders, Variational Autoencoders (VAE) • Generative Adversarial Network (GAN)




Recurrent Neural Network

Recurrent Neural Network (RNN) adalah salah satu arsitektur ANN yang mampu merepresentasikan data *sequential* misalnya teks, dna, suara, *time series*, dan sebagainya




$$\hat{y}_t = H_t W_{hy} + b_y$$

$$H_t = \phi(X_t W_{xh} + H_{t-1} W_{hh} + b_h)$$




Tipe arsitektur RNN dan aplikasinya



Many to One

Applications:


- Sentiment classification
- Opinion mining
- Speech recognition
- Automated answer scoring



One to Many

Applications:

- Image captioning
- Text generation





Many to Many

Applications:

- Translation
- Forecasting
- Chatbot
- Music generation





Contoh Aplikasi: *Sentiment classification* & *Image captioning*



Varian Arsitektur RNN

<http://dprogrammer.org/rnn-lstm-gru>

- **Long Short-Term Memory (LSTM):** merupakan salah satu jenis arsitektur RNN yang terdiri dari beberapa unit yaitu input gate, output gate, dan forget gate
- **Gate Recurrent Unit (GRU):** merupakan simplifikasi dari arsitektur LSTM dengan menggabungkan input gate dan forget gate sehingga jumlah parameter lebih sedikit
- **Independently RNN (IndRNN):** arsitektur RNN dimana setiap neuron dalam satu layer independen dari yang lain
- **Bi-directional RNN:** merupakan arsitektur RNN menghubungkan dua hidden layer dari arah yang berlawanan ke output yang sama.
- **Echo State Network (ESN):** ide dasar ESN adalah untuk membuat jaringan berulang yang terhubung secara acak, yang disebut reservoir



Summary

FCN

Data numerik

Jumlah hidden layer
sesuai kompleksitas
permasalahan

Klasifikasi dan regresi

CNN

Data citra, video

Convolution & Pooling
layer

Klasifikasi, deteksi obyek,
instance segmentation,
generate citra sintetis

RNN

Data text, signal, suara,
time-series

Konsep recurrent dan
memperhatikan urutan
input

Klasifikasi, regresi,
generate text, translation

Karakteristik Deep Learning

- Supervised, Semi-Supervised atau Unsupervised
- Memerlukan sumber daya yang besar → CPU + GPU
- Model terdiri dari banyak layer (bisa mencapai ribuan layer)
- Optimasi Hyper-parameters (epoch, layer, learning rate, dll)
- Memiliki fungsi biaya (cost function) – MAE, MSE, Hinge loss, dll

Deep Learning: Programming & Libraries



Caffe



theano

PYTORCH

