

# **Unsupervised Learning-K-means Clustering**

## Tujuan Pembelajaran


- ❑ Mahasiswa dapat memahami konsep pembelajaran tidak terawasi (unsupervised learning), khususnya menggunakan metode K-Means clustering
- ❑ Mahasiswa dapat menjelaskan beberapa penerapan algoritma klustering dalam menyelesaikan berbagai masalah.

# Outline

- ❑ Pengantar Clustering
- ❑ Penerapan Algoritma Clustering
- ❑ Macam-macam Algoritma Clustering
- ❑ Langkah Algoritma K-Means Clustering
- ❑ Contoh Perhitungan Algoritma K-Means
- ❑ Optimasi Nilai  $k$  pada K-Means

# Supervised vs Unsupervised Learning

- ☐ Supervised
  - Classification
  - Regression
- ☐ Unsupervised
  - Clustering
  - Association
  - Dimension Reduction



# Pengantar

- Diberikan data profil pelanggan (customer), **bagaimana memilih data pelanggan** yang potensial untuk ditawarkan produk tertentu?

|     | Customer Id | Age | Edu | Years Employed | Income | Card Debt | Other Debt | Defaulted | Address | DebtIncomeRatio |
|-----|-------------|-----|-----|----------------|--------|-----------|------------|-----------|---------|-----------------|
| 0   | 1           | 41  | 2   | 6              | 19     | 0.124     | 1.073      | 0.0       | NBA001  | 6.3             |
| 1   | 2           | 47  | 1   | 26             | 100    | 4.582     | 8.218      | 0.0       | NBA021  | 12.8            |
| 2   | 3           | 33  | 2   | 10             | 57     | 6.111     | 5.802      | 1.0       | NBA013  | 20.9            |
| 3   | 4           | 29  | 2   | 4              | 19     | 0.681     | 0.516      | 0.0       | NBA009  | 6.3             |
| 4   | 5           | 47  | 1   | 31             | 253    | 9.308     | 8.908      | 0.0       | NBA008  | 7.2             |
| ... | ...         | ... | ... | ...            | ...    | ...       | ...        | ...       | ...     | ...             |
| 845 | 846         | 27  | 1   | 5              | 26     | 0.548     | 1.220      | NaN       | NBA007  | 6.8             |
| 846 | 847         | 28  | 2   | 7              | 34     | 0.359     | 2.021      | 0.0       | NBA002  | 7.0             |
| 847 | 848         | 25  | 4   | 0              | 18     | 2.802     | 3.210      | 1.0       | NBA001  | 33.4            |
| 848 | 849         | 32  | 1   | 12             | 28     | 0.116     | 0.696      | 0.0       | NBA012  | 2.9             |
| 849 | 850         | 52  | 1   | 16             | 64     | 1.866     | 3.638      | 0.0       | NBA025  | 8.6             |

850 rows × 10 columns

Kita diminta untuk mengelompokkan data customer di samping, berdasarkan kesamaan profil pelanggan



Customer Segmentation



Clustering

# Pengantar


## ❑ Contoh hasil clustering / segmentasi pelanggan

|     | Customer Id | Age | Edu | Years Employed | Income | Card Debt | Other Debt | Defaulted | DebtIncomeRatio | Cluster |
|-----|-------------|-----|-----|----------------|--------|-----------|------------|-----------|-----------------|---------|
| 0   | 1           | 41  | 2   | 6              | 19     | 0.124     | 1.073      | 0.0       | 6.3             | 2       |
| 1   | 2           | 47  | 1   | 26             | 100    | 4.582     | 8.218      | 0.0       | 12.8            | 0       |
| 2   | 3           | 33  | 2   | 10             | 57     | 6.111     | 5.802      | 1.0       | 20.9            | 2       |
| 3   | 4           | 29  | 2   | 4              | 19     | 0.681     | 0.516      | 0.0       | 6.3             | 2       |
| 4   | 5           | 47  | 1   | 31             | 253    | 9.308     | 8.908      | 0.0       | 7.2             | 1       |
| ... | ...         | ... | ... | ...            | ...    | ...       | ...        | ...       | ...             | ...     |
| 845 | 846         | 27  | 1   | 5              | 26     | 0.548     | 1.220      | NaN       | 6.8             | 2       |
| 846 | 847         | 28  | 2   | 7              | 34     | 0.359     | 2.021      | 0.0       | 7.0             | 2       |
| 847 | 848         | 25  | 4   | 0              | 18     | 2.802     | 3.210      | 1.0       | 33.4            | 2       |
| 848 | 849         | 32  | 1   | 12             | 28     | 0.116     | 0.696      | 0.0       | 2.9             | 2       |
| 849 | 850         | 52  | 1   | 16             | 64     | 1.866     | 3.638      | 0.0       | 8.6             | 0       |

Setiap pelanggan berhasil dikelompokkan

# Apa itu Clustering?

- ❑ **Cluster** adalah sekumpulan data / object yang memiliki **kesamaan (similarity)** diantara setiap anggota klaster, atau **ketidaksamaan (dissimilarity)** dengan data pada klaster yang lain



# Contoh Penerapan Clustering

## ❑ Retail / Marketing

- Analisis pola transaksi yang dilakukan pelanggan
- Rekomendasi buku, film atau produk baru untuk pelanggan baru

## ❑ Perbankan

- Deteksi fraud dalam transaksi perbankan
- Pengelompokan nasabah (program loyalitas nasabah)

## ❑ Asuransi

- Deteksi fraud dalam klaim asuransi
- Analisis resiko asuransi bagi pelanggan

## ❑ Berita dan Penerbitan

- Kategorisasi berita secara otomatis
- Rekomendasi artikel / berita baru

# Penggunaan Algoritma Clustering

- ❑ Exploratory Data Analysis (EDA)
- ❑ Generate Rangkuman (summary generation)
- ❑ Deteksi pencilan (outlier detection)
- ❑ Mencari duplikat (finding duplicates)
- ❑ Tahap pra-pemrosesan data (Data pre-processing)
- ❑ Kompresi data / image
- ❑ Optimasi algoritma k-NN
- ❑ dll

# Algoritma Clustering

## □ Partitioning-based clustering




- K-Means,
- K-Medoid,
- K-Medians,
- Fuzzy C-Means, dll

## □ Hierarchical Clustering

- Agglomerative
- Divisive, dll

## □ Density-based Clustering

- DBSCAN, dll



**Partitioning-based Clustering**

**Algoritma K-means**

# K-Means Clustering

- ❑ Algoritma K-Means adalah salah satu algoritma clustering yang bersifat **iteratif** yang mencoba untuk mempartisi dataset menjadi **subkelompok non-overlapping** berbeda yang ditentukan oleh **K (cluster)** yang mana setiap titik data hanya dimiliki oleh satu kelompok.
- ❑ K-Means mencoba membuat titik data **intra-cluster semirip mungkin dengan titik data** yang lain pada satu cluster.
- ❑ K-Means menetapkan poin data ke cluster sedemikian rupa sehingga jumlah jarak kuadrat antara titik data dan pusat massa cluster (centroid) adalah minimal.
- ❑ Semakin sedikit variasi dalam sebuah cluster, semakin homogen (serupa) titik data dalam cluster yang sama.


# K-Means Clustering: Similarity / Dissimilarity

## □ Intra-cluster:

- Memaksimalkan similarity (kesamaan) di dalam klaster
- Meminimalkan dissimilarity di dalam klaster


## □ Inter-cluster:

- Meminimalkan similarity antar-klaster
- Memaksimalkan dissimilarity antar-klaster




# K-Means Clustering: Metode Perhitungan Similarity


- ☐ Jarak Euclidean
- ☐ Jarak City-Block
- ☐ Jarak Kotak Catur (Chebychef)
- ☐ Jarak Minkowski
- ☐ Jarak Canberra
- ☐ Jarak Bray-Curtis (Sorensen)
- ☐ Divergensi Kullback Leibler
- ☐ Divergensi Jensen Shannon
- ☐ dll




(a) jarak *Euclidean*



(b) Jarak *city-block*



(c) Jarak *Chebychef*



$$\sqrt{(x_2 - x_1)^2 + (y_2 - y_1)^2}$$

## Langkah / Algoritma K-Means Clustering

1. Tentukan jumlah kluster (nilai  $k$ )
2. Inisialisasi nilai centroid awal setiap kluster secara acak
3. Hitung jarak setiap titik data dengan setiap centroid
4. Masukkan setiap titik data ke dalam kluster berdasarkan jarak terdekat dengan pusat kluster
5. Untuk setiap kluster, tentukan nilai centroid baru berdasarkan rerata (means) dari setiap data di dalam kluster
6. Ulangi langkah 3-5 sedemikian hingga tidak ada perubahan anggota kluster.

# Ilustrasi Cara Kerja Algoritma K-Means




# Contoh Kasus: Klasterisasi Pelanggan

## Data Pelanggan

| CustID | Age | Income |
|--------|-----|--------|
| 1      | 41  | 19     |
| 2      | 47  | 100    |
| 3      | 33  | 57     |
| 4      | 29  | 19     |
| 5      | 47  | 253    |
| 6      | 40  | 81     |
| 7      | 38  | 56     |
| 8      | 42  | 64     |
| 9      | 26  | 18     |
| 10     | 47  | 115    |



Diketahui data pelanggan sebagaimana tabel di samping, kita diminta mengelompokkan data pelanggan menjadi 2 (dua) kelompok.



# Contoh Kasus: Klasterisasi Pelanggan

1. Tentukan jumlah klaster. Dalam contoh kasus ini kita gunakan nilai  $k=2$

| CustID | Age | Income |
|--------|-----|--------|
| 1      | 41  | 19     |
| 2      | 47  | 100    |
| 3      | 33  | 57     |
| 4      | 29  | 19     |
| 5      | 47  | 253    |
| 6      | 40  | 81     |
| 7      | 38  | 56     |
| 8      | 42  | 64     |
| 9      | 26  | 18     |
| 10     | 47  | 115    |



# Contoh Kasus: Klasterisasi Pelanggan

## 2. Inisialisasi nilai centroid awal setiap klaster secara acak

| CustID | Age | Income |
|--------|-----|--------|
| 1      | 41  | 19     |
| 2      | 47  | 100    |
| 3      | 33  | 57     |
| 4      | 29  | 19     |
| 5      | 47  | 253    |
| 6      | 40  | 81     |
| 7      | 38  | 56     |
| 8      | 42  | 64     |
| 9      | 26  | 18     |
| 10     | 47  | 115    |

### Cara penentuan centroid awal:


1. Memilih salah satu data untuk atribut “Age” dan “Income” secara acak
2. Membangkitkan bilangan acak sesuai rentang nilai “Age” dan “Income”

Dalam contoh ini kita memilih centroid awal dengan cara 1, kita tentukan **C1 = (41,19)** dan **C2 = (47,100)**

# Contoh Kasus: Klasterisasi Pelanggan

## 2. Inisialisasi nilai centroid awal setiap kluster secara acak

| CustID | Age | Income |
|--------|-----|--------|
| 1      | 41  | 19     |
| 2      | 47  | 100    |
| 3      | 33  | 57     |
| 4      | 29  | 19     |
| 5      | 47  | 253    |
| 6      | 40  | 81     |
| 7      | 38  | 56     |
| 8      | 42  | 64     |
| 9      | 26  | 18     |
| 10     | 47  | 115    |



# Contoh Kasus: Klasterisasi Pelanggan

## 3. Hitung jarak setiap titik data dengan setiap centroid. Contoh: Euclidean Distance

| CustID | Age | Income | Jarak ke C1(41,19)                           | Jarak ke C2(47,100)                          |
|--------|-----|--------|----------------------------------------------|----------------------------------------------|
| 1      | 41  | 19     | $\sqrt{(41 - 41)^2 + (19 - 19)^2} = 0$       | $\sqrt{(41 - 47)^2 + (19 - 100)^2} = 81,22$  |
| 2      | 47  | 100    | $\sqrt{(47 - 41)^2 + (100 - 19)^2} = 81,22$  | $\sqrt{(47 - 47)^2 + (100 - 100)^2} = 0$     |
| 3      | 33  | 57     | $\sqrt{(33 - 41)^2 + (57 - 19)^2} = 38,83$   | $\sqrt{(33 - 47)^2 + (57 - 100)^2} = 45,22$  |
| 4      | 29  | 19     | $\sqrt{(29 - 41)^2 + (19 - 19)^2} = 12,0$    | $\sqrt{(29 - 47)^2 + (19 - 100)^2} = 82,98$  |
| 5      | 47  | 253    | $\sqrt{(47 - 41)^2 + (253 - 19)^2} = 234,08$ | $\sqrt{(47 - 47)^2 + (253 - 100)^2} = 153,0$ |
| 6      | 40  | 81     | $\sqrt{(40 - 41)^2 + (81 - 19)^2} = 62,01$   | $\sqrt{(40 - 47)^2 + (81 - 100)^2} = 20,25$  |
| 7      | 38  | 56     | $\sqrt{(38 - 41)^2 + (56 - 19)^2} = 37,12$   | $\sqrt{(38 - 47)^2 + (56 - 100)^2} = 44,91$  |
| 8      | 42  | 64     | $\sqrt{(42 - 41)^2 + (64 - 19)^2} = 45,01$   | $\sqrt{(42 - 47)^2 + (64 - 100)^2} = 36,35$  |
| 9      | 26  | 18     | $\sqrt{(26 - 41)^2 + (18 - 19)^2} = 15,03$   | $\sqrt{(26 - 47)^2 + (18 - 100)^2} = 84,65$  |
| 10     | 47  | 115    | $\sqrt{(47 - 41)^2 + (115 - 19)^2} = 96,19$  | $\sqrt{(47 - 47)^2 + (115 - 100)^2} = 15,0$  |

# Contoh Kasus: Klasterisasi Pelanggan

## 4. Masukkan setiap titik data ke dalam klaster berdasarkan jarak terdekat dengan centroid

| CustID | Age | Income | Jarak ke C1(41,19)                           | Jarak ke C2(47,100)                          | Klaster |
|--------|-----|--------|----------------------------------------------|----------------------------------------------|---------|
| 1      | 41  | 19     | $\sqrt{(41 - 41)^2 + (19 - 19)^2} = 0$       | $\sqrt{(41 - 47)^2 + (19 - 100)^2} = 81,22$  | 1       |
| 2      | 47  | 100    | $\sqrt{(47 - 41)^2 + (100 - 19)^2} = 81,22$  | $\sqrt{(47 - 47)^2 + (100 - 100)^2} = 0$     | 2       |
| 3      | 33  | 57     | $\sqrt{(33 - 41)^2 + (57 - 19)^2} = 38,83$   | $\sqrt{(33 - 47)^2 + (57 - 100)^2} = 45,22$  | 1       |
| 4      | 29  | 19     | $\sqrt{(29 - 41)^2 + (19 - 19)^2} = 12,0$    | $\sqrt{(29 - 47)^2 + (19 - 100)^2} = 82,98$  | 1       |
| 5      | 47  | 253    | $\sqrt{(47 - 41)^2 + (253 - 19)^2} = 234,08$ | $\sqrt{(47 - 47)^2 + (253 - 100)^2} = 153,0$ | 2       |
| 6      | 40  | 81     | $\sqrt{(40 - 41)^2 + (81 - 19)^2} = 62,01$   | $\sqrt{(40 - 47)^2 + (81 - 100)^2} = 20,25$  | 2       |
| 7      | 38  | 56     | $\sqrt{(38 - 41)^2 + (56 - 19)^2} = 37,12$   | $\sqrt{(38 - 47)^2 + (56 - 100)^2} = 44,91$  | 1       |
| 8      | 42  | 64     | $\sqrt{(42 - 41)^2 + (64 - 19)^2} = 45,01$   | $\sqrt{(42 - 47)^2 + (64 - 100)^2} = 36,35$  | 2       |
| 9      | 26  | 18     | $\sqrt{(26 - 41)^2 + (18 - 19)^2} = 15,03$   | $\sqrt{(26 - 47)^2 + (18 - 100)^2} = 84,65$  | 1       |
| 10     | 47  | 115    | $\sqrt{(47 - 41)^2 + (115 - 19)^2} = 96,19$  | $\sqrt{(47 - 47)^2 + (115 - 100)^2} = 15,0$  | 2       |

# Contoh Kasus: Klasterisasi Pelanggan

4. Masukkan setiap titik data ke dalam klaster berdasarkan jarak terdekat dengan centroid

## Klaster 1

- Cust 1
- Cust 3
- Cust 4
- Cust 7
- Cust 9

## Klaster 2

- Cust 2
- Cust 5
- Cust 6
- Cust 8
- Cust 10

# Contoh Kasus: Klasterisasi Pelanggan

5. Untuk setiap klaster, hitung nilai centroid baru berdasarkan rerata (means) dari setiap data di dalam klaster

| CustID | Age | Income | Jarak ke C1(41,19)                     | Jarak ke C2(47,100)                    | Klaster |
|--------|-----|--------|----------------------------------------|----------------------------------------|---------|
| 1      | 41  | 19     | $\sqrt{(41-41)^2+(19-19)^2} = 0$       | $\sqrt{(41-47)^2+(19-100)^2} = 81,22$  | 1       |
| 2      | 47  | 100    | $\sqrt{(47-41)^2+(100-19)^2} = 81,22$  | $\sqrt{(47-47)^2+(100-100)^2} = 0$     | 2       |
| 3      | 33  | 57     | $\sqrt{(33-41)^2+(57-19)^2} = 38,83$   | $\sqrt{(33-47)^2+(57-100)^2} = 45,22$  | 1       |
| 4      | 29  | 19     | $\sqrt{(29-41)^2+(19-19)^2} = 12,0$    | $\sqrt{(29-47)^2+(19-100)^2} = 82,98$  | 1       |
| 5      | 47  | 253    | $\sqrt{(47-41)^2+(253-19)^2} = 234,08$ | $\sqrt{(47-47)^2+(253-100)^2} = 153,0$ | 2       |
| 6      | 40  | 81     | $\sqrt{(40-41)^2+(81-19)^2} = 62,01$   | $\sqrt{(40-47)^2+(81-100)^2} = 20,25$  | 2       |
| 7      | 38  | 56     | $\sqrt{(38-41)^2+(56-19)^2} = 37,12$   | $\sqrt{(38-47)^2+(56-100)^2} = 44,91$  | 1       |
| 8      | 42  | 64     | $\sqrt{(42-41)^2+(64-19)^2} = 45,01$   | $\sqrt{(42-47)^2+(64-100)^2} = 36,35$  | 2       |
| 9      | 26  | 18     | $\sqrt{(26-41)^2+(18-19)^2} = 15,03$   | $\sqrt{(26-47)^2+(18-100)^2} = 84,65$  | 1       |
| 10     | 47  | 115    | $\sqrt{(47-41)^2+(115-19)^2} = 96,19$  | $\sqrt{(47-47)^2+(115-100)^2} = 15,0$  | 2       |

Centroid Baru

C1 = (mean(41;33;29;38;26), mean(19;57;19;56;18)) = (33,4; 33,8)

# Contoh Kasus: Klasterisasi Pelanggan

5. Untuk setiap klaster, hitung nilai centroid baru berdasarkan rerata (means) dari setiap data di dalam klaster


| CustID | Age | Income | Jarak ke C1(41,19)                           | Jarak ke C2(47,100)                          | Klaster |
|--------|-----|--------|----------------------------------------------|----------------------------------------------|---------|
| 1      | 41  | 19     | $\sqrt{(41 - 41)^2 + (19 - 19)^2} = 0$       | $\sqrt{(41 - 47)^2 + (19 - 100)^2} = 81,22$  | 1       |
| 2      | 47  | 100    | $\sqrt{(47 - 41)^2 + (100 - 19)^2} = 81,22$  | $\sqrt{(47 - 47)^2 + (100 - 100)^2} = 0$     | 2       |
| 3      | 33  | 57     | $\sqrt{(33 - 41)^2 + (57 - 19)^2} = 38,83$   | $\sqrt{(33 - 47)^2 + (57 - 100)^2} = 45,22$  | 1       |
| 4      | 29  | 19     | $\sqrt{(29 - 41)^2 + (19 - 19)^2} = 12,0$    | $\sqrt{(29 - 47)^2 + (19 - 100)^2} = 82,98$  | 1       |
| 5      | 47  | 253    | $\sqrt{(47 - 41)^2 + (253 - 19)^2} = 234,08$ | $\sqrt{(47 - 47)^2 + (253 - 100)^2} = 153,0$ | 2       |
| 6      | 40  | 81     | $\sqrt{(40 - 41)^2 + (81 - 19)^2} = 62,01$   | $\sqrt{(40 - 47)^2 + (81 - 100)^2} = 20,25$  | 2       |
| 7      | 38  | 56     | $\sqrt{(38 - 41)^2 + (56 - 19)^2} = 37,12$   | $\sqrt{(38 - 47)^2 + (56 - 100)^2} = 44,91$  | 1       |
| 8      | 42  | 64     | $\sqrt{(42 - 41)^2 + (64 - 19)^2} = 45,01$   | $\sqrt{(42 - 47)^2 + (64 - 100)^2} = 36,35$  | 2       |
| 9      | 26  | 18     | $\sqrt{(26 - 41)^2 + (18 - 19)^2} = 15,03$   | $\sqrt{(26 - 47)^2 + (18 - 100)^2} = 84,65$  | 1       |
| 10     | 47  | 115    | $\sqrt{(47 - 41)^2 + (115 - 19)^2} = 96,19$  | $\sqrt{(47 - 47)^2 + (115 - 100)^2} = 15,0$  | 2       |

**Centroid Baru**

**C2** = (mean(47;47;40;42;47), mean(100;253;81;64;115)) = **(44,6; 122,6)**

# Contoh Kasus: Klasterisasi Pelanggan

Pergeseran Centroid setiap klaster.  $C1 = (33,4; 33,8)$  dan  $C2 = (44,6; 122,6)$



# Contoh Kasus: Klasterisasi Pelanggan

## 6. Ulangi langkah 3-5 menggunakan centroid baru

| CustID | Age | Income | Jarak ke C1(33,4; 33,8) | Jarak ke C2(44,6; 122,6) | Klaster |
|--------|-----|--------|-------------------------|--------------------------|---------|
| 1      | 41  | 19     | 16,64                   | 103,66                   | 1       |
| 2      | 47  | 100    | 67,58                   | 22,73                    | 2       |
| 3      | 33  | 57     | 23,20                   | 66,62                    | 1       |
| 4      | 29  | 19     | 15,44                   | 104,77                   | 1       |
| 5      | 47  | 253    | 219,62                  | 130,42                   | 2       |
| 6      | 40  | 81     | 47,66                   | 41,85                    | 2       |
| 7      | 38  | 56     | 22,67                   | 66,93                    | 1       |
| 8      | 42  | 64     | 31,40                   | 58,66                    | 1       |
| 9      | 26  | 18     | 17,45                   | 106,24                   | 1       |
| 10     | 47  | 115    | 82,33                   | 7,97                     | 2       |

# Contoh Kasus: Klasterisasi Pelanggan

## 6. Ulangi langkah 3-5 menggunakan centroid baru

| CustID | Age | Income | Jarak ke C1(33,4; 33,8) | Jarak ke C2(44,6; 122,6) | Klaster |
|--------|-----|--------|-------------------------|--------------------------|---------|
| 1      | 41  | 19     | 16,64                   | 103,66                   | 1       |
| 2      | 47  | 100    | 67,58                   | 22,73                    | 2       |
| 3      | 33  | 57     | 23,20                   | 66,62                    | 1       |
| 4      | 29  | 19     | 15,44                   | 104,77                   | 1       |
| 5      | 47  | 253    | 219,62                  | 130,42                   | 2       |
| 6      | 40  | 81     | 47,66                   | 41,85                    | 2       |
| 7      | 38  | 56     | 22,67                   | 66,93                    | 1       |
| 8      | 42  | 64     | 31,40                   | 58,66                    | 1       |
| 9      | 26  | 18     | 17,45                   | 106,24                   | 1       |
| 10     | 47  | 115    | 82,33                   | 7,97                     | 2       |

Apakah hasil klasterisasinya sama dengan tahap sebelumnya?

- Jika sama, hentikan proses klasterisasi
- Jika belum sama, ulangi langkah 3-5

# Contoh Kasus: Klasterisasi Pelanggan

| Data          |     |        | ITERASI 1 |            |
|---------------|-----|--------|-----------|------------|
| CustID        | Age | Income | C1(41,19) | C2(47,100) |
| 1             | 41  | 19     | 0,00      | 81,22      |
| 2             | 47  | 100    | 81,22     | 0,00       |
| 3             | 33  | 57     | 38,83     | 45,22      |
| 4             | 29  | 19     | 12,00     | 82,98      |
| 5             | 47  | 253    | 234,08    | 153,00     |
| 6             | 40  | 81     | 62,01     | 20,25      |
| 7             | 38  | 56     | 37,12     | 44,91      |
| 8             | 42  | 64     | 45,01     | 36,35      |
| 9             | 26  | 18     | 15,03     | 84,65      |
| 10            | 47  | 115    | 96,19     | 15,00      |
| Centroid Baru |     |        | 33,4      | 44,6       |
|               |     |        | 33,8      | 122,6      |



| ITERASI 2 |        |
|-----------|--------|
| C1        | C2     |
| 16,64     | 103,66 |
| 67,58     | 22,73  |
| 23,20     | 66,62  |
| 15,44     | 104,77 |
| 219,62    | 130,42 |
| 47,66     | 41,85  |
| 22,67     | 66,93  |
| 31,40     | 58,66  |
| 17,45     | 106,24 |
| 82,33     | 7,97   |
| 34,83     | 45,25  |
| 38,83     | 137,25 |



| ITERASI 3 |        |
|-----------|--------|
| C1        | C2     |
| 20,77     | 118,33 |
| 62,36     | 37,29  |
| 18,26     | 81,18  |
| 20,67     | 119,36 |
| 214,51    | 115,76 |
| 42,48     | 56,49  |
| 17,46     | 81,57  |
| 26,17     | 73,32  |
| 22,63     | 120,79 |
| 77,13     | 22,32  |
| 35,57     | 47,00  |
| 44,86     | 156    |



| ITERASI 4 |        |
|-----------|--------|
| C1        | C2     |
| 26,42     | 137,13 |
| 56,31     | 56,00  |
| 12,41     | 99,98  |
| 26,68     | 138,18 |
| 208,46    | 97,00  |
| 36,41     | 75,33  |
| 11,40     | 100,40 |
| 20,19     | 92,14  |
| 28,51     | 139,59 |
| 71,07     | 41,00  |
| SELESAI   |        |

## Optimasi Nilai k pada K-Means


- ❑ Salah satu faktor krusial baik tidaknya metode K-Means adalah **jumlah klusternya (nilai K)**. Hasil pengelompokan akan menghasilkan analisa yang berbeda untuk jumlah kluster yang berbeda juga.
- ❑ **Semakin kecil nilai K** (misal 2), maka pembagian kluster menjadi cepat, namun mungkin ada informasi tersembunyi yang tidak terungkap.
- ❑ **Semakin besar nilai K** (misal  $K=10$ ), maka terlalu banyak kluster. Mungkin akan terlalu sulit untuk membuat analisa atau memilih dukungan keputusan dari hasil cluster.

# Optimasi Nilai k pada K-Means

- ❑ Penentuan nilai k terbaik dapat dilakukan berdasarkan ukuran kualitas hasil klasterisasi.
- ❑ Beberapa ukuran kualitas klaster:
  - Sum Square Error (SSE)
  - Davies-Bouldin Index (DBI)
  - Silhouette Coefficient
  - Rand Index
  - Mutual Information
  - Calinski-Harabasz Index (C-H Index)
  - Dunn Index

# Penentuan Nilai k Terbaik dengan Metode Elbow

- Untuk mengetahui jumlah kluster yang paling baik adalah dengan cara melihat perbandingan kualitas kluster untuk setiap pilihan nilai k (misal  $k=2, 3, 4, 5, \dots$ ).
- Nilai k yang dipilih adalah nilai k yang memiliki perubahan kualitas signifikan, seperti sebuah **siku (elbow)**.



# Kesimpulan

- ❑ Clustering merupakan salah satu metode pembelajaran tidak terawasi
- ❑ Metode clustering dibagi menjadi 3 jenis: partitioning-based, hierarchical, dan density-based.
- ❑ Algoritma K-means adalah salah satu algoritma clustering yang bersifat iteratif yang mempartisi dataset menjadi subkelompok non-overlapping berbeda yang ditentukan oleh K (cluster)
- ❑ Algoritma K-Means:
  - Relatif efisien untuk data kecil hingga besar
  - Menghasilkan kelompok kluster
  - Memerlukan inisialisasi nilai k

# Latihan

- ❑ Diketahui dataset
- ❑ Lakukan clustering dengan jumlah cluster = 3

| Lokasi toko | Harga produk | Kebersihan | Pelayanan kasir | Fasilitas | Keindahan interior |
|-------------|--------------|------------|-----------------|-----------|--------------------|
| 6           | 4            | 7          | 3               | 2         | 3                  |
| 2           | 3            | 1          | 4               | 5         | 4                  |
| 7           | 2            | 6          | 4               | 1         | 3                  |
| 4           | 6            | 4          | 5               | 3         | 6                  |
| 1           | 3            | 2          | 2               | 6         | 4                  |
| 6           | 4            | 6          | 3               | 3         | 4                  |
| 5           | 3            | 6          | 3               | 3         | 4                  |
| 7           | 3            | 7          | 4               | 1         | 4                  |
| 2           | 4            | 3          | 3               | 6         | 3                  |
| 3           | 5            | 3          | 6               | 4         | 6                  |
| 1           | 3            | 2          | 3               | 5         | 3                  |
| 5           | 4            | 5          | 4               | 2         | 4                  |
| 2           | 2            | 1          | 5               | 4         | 4                  |
| 4           | 6            | 4          | 6               | 4         | 7                  |
| 6           | 5            | 4          | 2               | 1         | 4                  |
| 3           | 5            | 4          | 6               | 4         | 7                  |
| 4           | 4            | 7          | 2               | 2         | 5                  |
| 3           | 7            | 2          | 6               | 4         | 3                  |
| 4           | 6            | 3          | 7               | 2         | 7                  |
| 2           | 3            | 2          | 4               | 7         | 2                  |